

Nome: Gabriel Ribeiro Passos

Victor de Souza Vilela da Silva

Relatório de Classificação do Dataset MNIST

1. Características do Dataset:

O conjunto de dados utilizado neste projeto é o Fashion MNIST, que é um conjunto de imagens em escala de cinza de 28x28 pixels representando artigos de vestuário. O dataset possui as seguintes características:

- Tamanho do conjunto de treinamento: 60.000 amostras.
- Tamanho do conjunto de teste: 10.000 amostras.
- Formato das imagens: 28x28 pixels em escala de cinza.
- Categorias: 10 (T-shirt/top, Trouser, Pullover, Dress, Coat, Sandal, Shirt, Sneaker, Bag, Ankle boot).
- Balanceamento: O dataset é relativamente balanceado, com a mesma quantidade de amostrar para cada categoria.

2. Técnica de Classificação Utilizada

A técnica utilizada para classificar o dataset é o Perceptron Multicamadas (MLP), um tipo de rede neural artificial. A configuração utilizada no MLP é de duas camadas ocultas, cada uma com 10 neurônios. O número máximo de iterações para o solver convergir é de 500. A função de ativação utilizada é a ReLU (Rectified Linear Unit) e o solver utilizado para otimização de peso é o Adam.

A escolha do MLP se dá pela sua capacidade de aprender através de exemplos e sua habilidade de generalizar a partir desses aprendizados. A função de ativação ReLU é comumente utilizada em redes neurais por causa de suas propriedades, como a não saturação da parte positiva e a eficiência computacional. O solver Adam é uma escolha popular por ser eficiente e requerer pouca memória.

3. Resultados Obtidos

A seguir os resultados de 5 execuções com dados de validação contendo 15 itens.

Resultado 1

Acuracia do modelo: 0.6832

Predicted: [8 8 7 2 8 4 1 6 4 5 3 7 0 9 4]

Expected: [8 8 7 4 8 4 1 0 4 5 3 7 4 9 4]

Resultado 2

Acuracia do modelo: 0.6863

Predicted: [8 8 7 2 8 2 1 0 2 5 3 7 0 9 2]

Expected: [8 8 7 4 8 4 1 0 4 5 3 7 4 9 4]

Resultado 3

Acuracia do modelo: 0.7488

Predicted: [8 8 7 2 8 2 1 0 2 5 0 7 4 9 2]

Expected: [8 8 7 4 8 4 1 0 4 5 3 7 4 9 4]

Resultado 4

Acuracia do modelo: 0.6418

Predicted: [9 8 7 4 8 4 1 6 4 7 0 7 0 9 4]

Expected: [8 8 7 4 8 4 1 0 4 5 3 7 4 9 4]

Resultado 5

Acuracia do modelo: 0.7841

Predicted: [8 8 7 4 8 4 1 0 4 5 1 7 4 9 4]

Expected: [8 8 7 4 8 4 1 0 4 5 3 7 4 9 4]

O código pode ser acessado pelo [link](#).

4. Conclusões

Atingir altos níveis de precisão em tarefas de classificação de imagens pode ser desafiador devido a vários fatores, como a qualidade e a quantidade de dados, a escolha do modelo e seus hiperparâmetros. No entanto, técnicas como redes neurais, que são capazes de aprender representações de alto nível dos dados, têm se mostrado eficazes nesse tipo de tarefa. A escolha dos hiperparâmetros também é crucial para o desempenho do modelo e muitas vezes requer experimentação e ajuste fino. Além disso, técnicas como validação cruzada e aumento de dados podem ser usadas para melhorar a precisão do modelo.